Prüfbericht Bibel 1.8

Automatischer Referenzlauf 42686492874 · Repository kassenbuch-1-8-42686492874 · 2026-11-09

Teilbericht: Der Lauf wurde abgebrochen (Fehler: git clone -q D:\a\bibel-labor\lauf\kassenbuch-1-8-42686492874 D:\a\bibel-labor\lauf\manuell failed: fatal: destination path 'D:\a\bibel-labor\lauf\manuell' already exists and is not an empty directory.).

1. Ergebnis

Dies ist der erste gültige Lauf, ein Vergleich mit einer Vorversion in Prozent ist deshalb nicht möglich (Verbrauch: 7,32 Mio. Tokens, 7,91 USD). Von 25 Regeln wurden 20 erfüllt, 4 waren nicht prüfbar, und 1 wurde nicht erfüllt: Die Prüfanleitung wurde nach der ersten Fassung nicht erneut von Menschen geprüft. Die Qualität der Software ist gut (alle 3 Aufgaben im Erstdurchlauf bestanden, 0 echte Befunde, 205 Tests, CI grün), aber die manuelle Prüfung ist nicht bestanden, weil 11 von 12 Schritten als problematisch eingestuft wurden.

2. Kennzahlen

Kennzahl	Vorversion	Bibel 1.8
Datum	–	2026-11-09
Claude-Code-Version	–	2.1.321 (Claude Code)
Tokens gesamt	–	7.320.645
Kostenschätzung (USD)	–	7,91
davon Koordinator	–	0,31
davon PO-Sitzungen (inkl. SP und QA)	–	7,60
Schritte	–	56
Aktive Laufzeit	–	39 Min.
Limit erreicht	–	ja, 180 Min. gewartet
Sitzungen	–	3
Aufgaben	–	3
Erstdurchlauf	–	100 %
QA-Runden	–	5
Echte Befunde	–	0
Rückfragen (davon unvorhergesehen)	–	3 (1)

Kennzahl	Vorversion	Bibel 1.8
Abgelehnte Berechtigungen	–	4
Regeltreue	–	20 / 25
Manuelle Prüfung (Minuten)	–	10
Tests, CI grün	–	205, ja
Bemerkung	–	Abgebrochen: Fehler: git clone -q D:\a\bibel-labor\lauf\kassenbuch-1-8-42686492874 D:\a\bibel-labor\lauf\manuell failed: fatal: destination path 'D:\a\bibel-labor\lauf\manuell' already exists and is not an empty directory.

Hilfsaufrufe (Entscheider, manuelle Prüfung, Auditor, Bericht) zusätzlich: 0,97 USD, nicht in der Kostenschätzung enthalten.

3. Regeltreue und Auswertung

Kennzahlen (Teil 3 §7)

Kennzahl	Wert	Beleg
Sitzungen	3 Sitzungen mit 6 Aufrufen: Koordinator, PO Plan, PO Block 1	lauf.jsonl, 3 verschiedene `session_id` (Zeilen 2–4 und 5–6 sind fortgesetzte Sitzungen)
Schritte (`num_turns`)	56 (8+3+16+3+18+8)	lauf.jsonl, Zeilen 1–6
Tokens gesamt	ca. 7,32 Mio. (Koordinator 0,27 · Plan 1,02 · Block 1 6,04 Mio.)	`modelUsage` im jeweils letzten Eintrag pro Sitzung; die Werte zählen innerhalb einer Sitzung weiter
Kosten (USD)	ca. 7,91 (0,31 + 1,26 + 6,34)	`total_cost_usd` , Zeilen 1, 4, 6
Aktive Laufzeit	ca. 34 min (2051 s `wall_s`)	lauf.jsonl
Aufgaben	3 (T001, T002, REL; keine eigene Härtungsaufgabe)	docs/backlog.md
Erstdurchlauf	100 % (3 von 3 mit PASS in der ersten QA-Runde)	docs/tasks/T001.md:44, T002.md:35, REL.md:39
QA-Runden	5 (T001: 1, T002: 1, REL: 3)	docs/tasks/REL.md:39, 73, 105
Echte Befunde	0 (nur Hinweise H1–H8 und zwei Hinweise zu REL)	docs/backlog.md:14–24
Rückfragen Planphase	3 (davon 1 Widerspruch N3/F02)	lauf.jsonl, Zeile 2, `antwort`
Abgelehnte Berechtigungen	4 (3 in Zeile 5, 1 in Zeile 6, alle Bash)	`permission_denials`
Manuelle Prüfung	12 Schritte, davon 11 problematisch, nicht bestanden; geschätzt 10 min	manuelle-pruefung.json

Kennzahl	Wert	Beleg
Tests	205	docs/tasks/REL.md:92
CI	grün (Lauf 42690243491 auf main f7ed6e6)	docs/status.md:6

Regelprüfung R1–R25

Regel	Ergebnis	Beleg
R1	erfüllt	Start-Commit 5c10bdd ändert nur CLAUDE.md, docs/design.md, docs/status.md (status-archive.md:8). `.claude/settings.json` setzt `model`, `autoMemoryEnabled: false` und den Test-Hook. Einen eigenen Diff gegen die Vorlage konnte ich nicht erzeugen, weil die Shell gesperrt war.
R2	erfüllt	Architektur vom SP ohne QA-Prüfung, keine zusätzliche Rolle, nur Freigabe 1 vor T001 (status-archive.md:15, HEAD-Log Zeilen 8–12)
R3	erfüllt	lauf.jsonl Zeile 2: „1. Widerspruch: Nicht-Ziel N3 und F02 …“ steht an erster Stelle
R4	erfüllt	lauf.jsonl Zeile 2: drei Rückfragen
R5	erfüllt	docs/gate-1.md:10 nennt Klasse S, Bereitstellung, Prüfperson und „Personenbezogene Daten: nein“; Architektur in Alltagssprache in Zeile 13
R6	erfüllt	architecture.md:31 „Gate-relevant decisions“, architecture.md:140 „Removing a feature“
R7	erfüllt	Alle drei Briefs haben „QA level“ (Zeile 2) und „## QA check criteria“
R8	erfüllt	backlog.md:9, letzte Zeile ist `REL`
R9	erfüllt	Neue PO-Sitzung für Plan und für Block 1 (verschiedene `session_id`); SP und QA laufen als Subagenten pro Aufgabe (status.md:20, 29, 38)
R10	erfüllt	status.md hat 52 Zeilen; 7 Übergaben, status-archive.md enthält 2 davon
R11	erfüllt	logs/refs/heads/main: Setup, Plan, T001, T002, je ein Squash-Commit mit ID
R12	erfüllt	kassenbuch/app.py:30 `cfg.flag("export_csv", True)`
R13	nicht prüfbar	Änderungswunsch Ä1 wurde im Lauf nicht gestellt (lauf.jsonl endet mit Freigabe 3)
R14	nicht prüfbar	Ä1 Teil b (SQLite) kam nicht vor
R15	nicht prüfbar	Kein Speicherwechsel im Lauf
R16	erfüllt	tests/core/test_config.py; ein leeres `KASSENBUCH_DATA` endet mit Exit 2 (status.md:38)
R17	erfüllt	tests/perf/test_list_perf.py mit 100.000 Einträgen ist grün (T001.md:48)
R18	nicht prüfbar	0 echte Befunde, also keine Fehlerbehebung
R19	erfüllt	Stufen C/B/C in den Briefs; T002 auf Stufe B prüft nur die Prüfkriterien (T002.md:44)
R20	erfüllt	ci.yml:5–11 `paths-ignore` für docs und md; kein CI-Lauf auf REL (status.md:20)
R21	erfüllt	status.md:29, 38 „CI green once checked“; Wartezeile in status.md:4

Regel	Ergebnis	Beleg
R22	erfüllt	origin/REL = 9013718 = lokal, origin/main = f7ed6e6; alle Branches liegen auf dem Remote
R23	nicht erfüllt	Erste Fassung fiel durch (manuelle-pruefung.json: `"bestanden": false`, Schritte 1, 7, 9 unklar); die überarbeitete Fassung wurde nicht erneut von Menschen geprüft
R24	erfüllt	PLAN erst nach „Freigeben“ gemergt (lauf.jsonl Zeile 4); REL nach „Zurück an PO“ nicht gemergt (status.md:12)
R25	erfüllt	ci.yml:24–25 Actions per SHA; requirements-dev.txt mit `==`; Negativtests für beschädigte Dateien und ungültige Eingaben (T001.md:50)

Größte Kostentreiber

1. **Eine lange PO-Sitzung für Block 1 mit allen SP- und QA-Subagenten.** Sie kostete 6,34 von 7,91 USD (80 %), las 5,48 Mio. Tokens aus dem Cache und lief 1328 s plus 375 s (lauf.jsonl, Zeilen 5–6).
2. **Die Nacharbeit nach der Rückgabe von Freigabe 3.** Sie kostete +1,47 USD (Zeile 6 minus Zeile 5) und brauchte zwei zusätzliche QA-Runden auf Stufe C, obwohl nur Doku geändert wurde (c4858b9, ac517c5; REL.md:73 und 105). Auslöser war eine Prüfanleitung, die ohne Entwicklerwissen nicht ausführbar war (manuelle-pruefung.json).
3. **Aufwendige QA auf Stufe C.** Dazu gehörten 23 bzw. 18 Mutationsproben, wörtliches Nachspielen der Anleitung in PowerShell und Versuche zur Zeichenkodierung (R2). Diese Versuche führten zu 4 abgelehnten Bash-Aufrufen (T001.md, status.md:20, `permission_denials` in den Zeilen 5–6).

4. Größte Kostentreiber

- **Eine lange PO-Sitzung für Block 1 mit allen Unterstützern und Prüfern:** 6,34 von 7,91 USD (80 %), 5,48 Mio. Tokens aus dem Zwischenspeicher gelesen, Laufzeit 1328 s plus 375 s (lauf.jsonl, Zeilen 5–6).
- **Nacharbeit nach der Rückgabe von Freigabe 3:** zusätzlich 1,47 USD (Zeile 6 minus Zeile 5) und zwei zusätzliche QA-Runden auf Stufe C, obwohl nur Dokumentation geändert wurde (REL.md:73 und 105). Auslöser war eine Prüfanleitung, die ohne Entwicklerwissen nicht ausführbar war (manuelle-pruefung.json).
- **Aufwendige QA auf Stufe C:** 23 bzw. 18 Mutationsproben, wörtliches Nachspielen der Anleitung in PowerShell und Versuche zur Zeichenkodierung (T001.md, status.md:20).

5. Auffälligkeiten

- **Abgelehnte Berechtigungen:** 4, alle für Bash (3 in Zeile 5, 1 in Zeile 6 von lauf.jsonl).
- **Abbruch:** Die manuelle Prüfung brach mit einem Fehler ab: Das Zielverzeichnis für `git clone` existierte schon und war nicht leer. Die Prüfung lief danach im vorhandenen Ordner, daher konnten die Anleitungsschritte 1 bis 3 (ZIP entpacken, Terminal öffnen) nicht ausgeführt werden.
- **Limit:** Die Wartezeit durch das Limit betrug 180 Minuten, die aktive Laufzeit 39 Minuten.
- **Rückfragen und Unvorhergesehenes:** 3 Rückfragen in der Planphase (eine davon ein Widerspruch zwischen Nicht-Ziel N3 und F02); 1 unvorhergesehene Frage.

- **Anzeigeprobleme:** In fast allen Prüfschritten erschienen Umlaute und das Euro-Zeichen als „�“, vermutlich wegen der umgeleiteten Ausgabe; ob sie in einem echten Terminal stimmen, blieb ungeprüft.
- **Nicht prüfbar:** Excel stand nicht zur Verfügung, das Öffnen der CSV-Datei wurde nicht getestet. Der Änderungswunsch wurde nicht gesendet, daher waren R13, R14, R15 und R18 nicht prüfbar.

6. Manuelle Prüfung

Bestanden: nein · geschätzte Dauer für einen Menschen: 10 Minuten · Schritte: 12

- Schritt 2: Die Umlaute in 'für' und 'überschrieben' erschienen als '�'. Das liegt vermutlich an meiner umgeleiteten Ausgabe (Codepage) und nicht an einem echten Terminal. Ich konnte nicht prüfen, ob sie dort richtig aussehen.
- Schritt 3: 'Keine Einträge' und das '€' erschienen als '�'. Die Ursache ist vermutlich dieselbe wie bei Schritt 2 und nicht sicher festzustellen.
- Schritt 4: Das '€', 'Brötchen' und 'Bäcker' erschienen als '�'. Der Rest der Zeile entsprach der Erwartung.
- Schritt 6: Das '€' und das 'é' erschienen als '�'. Das heutige Datum 09.11.2026 war korrekt.
- Schritt 7: Reihenfolge und Saldo 1.192,50 stimmten. Das '€' und die Umlaute erschienen als '�', also genau der Fall, vor dem die Anleitung warnt. Die Anleitung sagt nicht, was zu tun ist, wenn es so aussieht. Der Hinweis auf 'chcp' und Schritt 12 steht weit weg.
- Schritt 8: Die Fehlermeldung war inhaltlich richtig. Das 'Ü' in 'Ungültiger' erschien als '�'.
- Schritt 9: Fehlermeldung und unveränderte Liste waren richtig. Die Umlaute erschienen als '�'. Schritt 9 enthält zwei Befehle, und die Anleitung sagt nicht klar, dass beide getrennt eingegeben werden.
- Schritt 10: Die Meldung stimmte, und die CSV-Datei hat den richtigen Inhalt mit Kopfzeile und UTF-8-BOM. Excel steht nicht zur Verfügung, deshalb konnte ich das Öffnen und die Darstellung der Spalten nicht prüfen. Die Buchung 'Café' hat einen leeren Text, was die Anleitung nicht erwähnt.
- Schritt 11: Die Fehlermeldung stimmte. Das 'ä' in 'verändert' erschien als '�'. Das Änderungsdatum der Datei habe ich nicht verglichen.
- Schritt 12: Optionaler Schritt, nicht ausgeführt. Er braucht außerdem den Editor per Doppelklick, den ich nicht habe.
- Schritt 1: Funktioniert (Python 3.12.10). Die Anleitungsschritte 1 bis 3 (ZIP entpacken, Terminal über Rechtsklick öffnen) konnte ich nicht ausführen, weil ich im bereits vorhandenen Ordner gearbeitet habe. Außerdem fehlt in der Anleitung ein Hinweis, dass die Schritte 1 bis 12 in der Tabelle von den nummerierten Startschritten 1 bis 4 zu unterscheiden sind. Die Nummern doppeln sich.

Die Prüfung lief automatisch. Ein Mensch sollte die Verständlichkeit der Anleitung mit einer 10-Minuten-Stichprobe bestätigen.

7. Empfehlungen für die nächste Bibel-Version

1. **Prüfanleitung vor Freigabe 3 von einer Person ohne Entwicklerwissen testen lassen.** Befund: Die erste Fassung fiel durch (11 von 12 Schritten problematisch, R23 nicht erfüllt) und die Nacharbeit kostete 1,47 USD.
2. **Die Anleitung bei Zeichenkodierung ausdrücklich führen.** Sie sollte sagen, was zu tun ist, wenn Umlaute oder „€“ als „�“ erscheinen, und den Hinweis auf `chcp` an den Anfang

stellen statt weit weg in Schritt 12. Befund: Schritt 7 und fast alle weiteren Schritte zeigten „“.

3. **Anleitung klarer gliedern.** Die Nummern der Tabellenschritte 1 bis 12 sollten sich nicht mit den Startschritten 1 bis 4 doppeln, und Schritt 9 sollte zwei getrennt einzugebende Befehle klar benennen. Außerdem sollte die Anleitung erwähnen, dass die Buchung „Café“ einen leeren Text hat. Befund: manuelle-pruefung.json, Schritte 1, 9 und 10.
4. **Die manuelle Prüfung in einem frischen, leeren Verzeichnis starten.** Befund: Der Abbruch durch `git clone` in ein bereits vorhandenes Verzeichnis verhinderte die Prüfung der Schritte 1 bis 3.
5. **Die Stufe C bei reinen Dokumentationsänderungen begrenzen und Bash-Rechte für QA-Versuche vorab klären.** Befund: Zwei zusätzliche QA-Runden auf Stufe C nach einer reinen Doku-Änderung sowie 4 abgelehnte Bash-Aufrufe.