# Prüfbericht Bibel 1.9

Automatischer Referenzlauf 42722790412 · Repository kassenbuch-1-9-42722790412 · 2026-11-10

## 1. Ergebnis

Dies ist der erste gültige Lauf, ein Vergleich mit der Vorversion in Prozent ist daher nicht möglich (Gesamtkosten 19,49 USD, 118 Schritte, 79 aktive Minuten). Von 25 Regeln wurden 22 erfüllt; zwei (R13, R19) wurden nicht erfüllt und eine (R18) war nicht prüfbar. Die Qualität ist gut: Alle 333 Tests bestanden, die automatische Prüfung (CI) war grün, 5 von 7 Aufgaben (71 %) bestanden im ersten Durchlauf, und es gab nur 2 echte Befunde.

## 2. Kennzahlen

| Kennzahl | Vorversion | Bibel 1.9 |
|---|---|---|
| Datum | – | 2026-11-10 |
| Claude-Code-Version | – | 2.1.321 (Claude Code) |
| Tokens gesamt | – | 22.044.086 |
| Kostenschätzung (USD) | – | 19,49 |
| davon Koordinator | – | 0,27 |
| davon PO-Sitzungen (inkl. SP und QA) | – | 19,21 |
| Schritte | – | 118 |
| Aktive Laufzeit | – | 79 Min. |
| Limit erreicht | – | ja, 240 Min. gewartet |
| Sitzungen | – | 7 |
| Aufgaben | – | 7 |
| Erstdurchlauf | – | 71 % |
| QA-Runden | – | 9 |
| Echte Befunde | – | 2 |
| Rückfragen (davon unvorhergesehen) | – | 6 (2) |
| Abgelehnte Berechtigungen | – | 6 |
| Regeltreue | – | 22 / 25 |
| Manuelle Prüfung (Minuten) | – | 8 |
| Tests, CI grün | – | 333, ja |
| Bemerkung | – | Automatischer Lauf 42722790412 |

Hilfsaufrufe (Entscheider, manuelle Prüfung, Auditor, Bericht) zusätzlich: 1,16 USD, nicht in der Kostenschätzung enthalten.

## 3. Regeltreue und Auswertung

### Tabelle 1: Kennzahlen (Teil 3 §7)

| Kennzahl | Wert | Beleg |
|---|---|---|
| Sitzungen | 7 (Koordinator 1, PO 6: Plan, Block 1, Change, Block 2 ×2, Release) | `lauf.jsonl`, 7 verschiedene `session_id` |
| Schritte (`num_turns`) | 118 (8+3+9+2+23+4+23+3+8+13+18+4) | `lauf.jsonl`, Zeilen 1–12 |
| Kostenschätzung | ≈ 19,49 USD (letzter Wert je Sitzung: 0,27 / 1,06 / 4,96 / 3,34 / 5,82 / 1,36 / 2,68) | `lauf.jsonl`, `total_cost_usd` |
| Aufgaben | 7 (T001–T006, REL; davon 2 Härtungsaufgaben) | `docs/backlog.md` |
| Erstdurchlauf | 5 von 7 = 71 % (T006 und REL mit Befund in Runde 1) | `docs/tasks/T006.md:68`, `docs/tasks/REL.md:134` |
| QA-Runden | 9 Runden zu Aufgaben, dazu 2 Architektur-Reviews in der Phase CHANGE | `.git/logs/HEAD` 43, 48, 79–81, 93–95 |
| Echte Befunde | 2 (T006: CHANGELOG-Eintrag zerteilt; REL F1: Testlücke beim schreibgeschützten Altbestand) | `T006.md:71`, `REL.md:164` |
| Abgelehnte Berechtigungen | 6, alle Bash (1 im Block 1, 5 im Release wegen powershell.exe) | `lauf.jsonl`, Zeilen 5 und 11 |
| Tests | 333 bestanden | `REL.md:120` |
| CI | grün (Lauf 42759208668 auf d92b28a, danach nur Doku-Commits) | `docs/status.md:14`, `:31` |

### Tabelle 2: Regelprüfung R1–R25

| Regel | Ergebnis | Beleg |
|---|---|---|
| R1 | erfüllt | Start-Commit 5f81359 ändert nur CLAUDE.md, design.md und status.md (`status-archive.md:112`; den Diff selbst konnte ich nicht ausführen, weil Bash gesperrt war); `settings.json`: model, `autoMemoryEnabled:false`, Test-Hook |
| R2 | erfüllt | Kein QA-Review der Architektur in der Planphase, eine Freigabe vor T001 (`status-archive.md:91–104`) |
| R3 | erfüllt | Erste Rückfrage des PO: „1. Widerspruch: N3 und F02“ (`lauf.jsonl`, Zeile 2) |
| R4 | erfüllt | Plan: 5 Rückfragen, Change: 4 (`lauf.jsonl`, Zeilen 2 und 6) |
| R5 | erfüllt | `docs/gates/freigabe-1.md:12–26` nennt Klasse, Bereitstellung, Prüfperson, „Personenbezogene Daten: nein“ und die Architektur in Alltagssprache |
| R6 | erfüllt | `architecture.md:34` „Gate-relevant decisions“, `:260` „Removing a feature“ |
| R7 | erfüllt | Alle 7 Briefs haben „QA level“ und „QA check criteria“ (`docs/tasks/*.md`, Zeile 2) |
| R8 | erfüllt | Letzte Backlog-Zeile ist REL (`backlog.md:12`) |

| Regel | Ergebnis | Beleg |
|---|---|---|
| R9 | erfüllt | Eigene PO-Sitzung je Phase bzw. Block; SP und QA als Subagenten |
| R10 | erfüllt | `status.md` hat 95 Zeilen, `status-archive.md` hat 8 Übergaben |
| R11 | erfüllt | `main` = Setup plus Squash-Merges PLAN, T001…T006, CHANGE, REL, alle mit ID ( `.git/logs/HEAD` 12–100) |
| R12 | erfüllt | T002: „F02 CSV export behind flag `export_csv` “ ( `backlog.md:7` ) |
| R13 | nicht erfüllt | Der T004-Diff berührt auch `core/errors.py` und `core/domain.py` ( `status.md:88–89` ) |
| R14 | erfüllt | T005 ist „Touches gate: yes“, QA-Review plus Re-Review (415f772, 227cb5e), erneute Freigabe in `docs/gates/freigabe-change.md` |
| R15 | erfüllt (knapp) | Kern des Diffs: `adapters/store.py` und `legacy_json.py` ; zusätzlich `core/*` für die Pfadregel ( `status.md:70–71` ) |
| R16 | erfüllt | `tests/features/entries/test_storage.py:316` (Endungsregel), `tests/adapters/test_store.py:266` (fehlender Ordner) |
| R17 | erfüllt | `tests/perf/test_list_perf.py` , auf CI grün (0,35 s, `status.md:65` ) |
| R18 | nicht prüfbar | Beide Befunde (Doku, Testlücke) waren keine Codefehler; im Branch-Verlauf gibt es keinen eigenen roten Test-Commit (d92b28a) |
| R19 | nicht erfüllt | QA auf Stufe B hat in T006 trotzdem die volle Suite ausgeführt: „full suite incl. perf 330 passed“ ( `T006.md:91` ) |
| R20 | erfüllt | `ci.yml:5–11` `paths-ignore` für `docs/**` und `*.md` ; PLAN und CHANGE ohne CI gemergt |
| R21 | erfüllt | Kein `gh run watch` und keine Schleife im Protokoll; QA vermerkt „not polled“; Wartezeile in `status.md:4` |
| R22 | erfüllt | Für jeden Branch PLAN…REL gibt es `refs/remotes/origin/*` ; jede Übergabe nennt einen Branch |
| R23 | erfüllt | `docs/manual-test.md` : Deutsch, Windows 11 und PowerShell, Hinweise für Nicht-Entwickler |
| R24 | erfüllt | Ausdrückliche Freigaben 1, Change und 3 sind vor dem Merge vermerkt ( `freigabe-1.md:48` , `status.md:12` ) |
| R25 | erfüllt | Actions per SHA eingebunden ( `ci.yml:21–22` ), `requirements-dev.txt` mit `==` , Negativtests (z. B. `test_parse_date_rejects_invalid` ) |

### Drei größte Kostentreiber

1. **PO-Sitzung Block 2 (T004+T005), 5,82 USD:** T005 brauchte 8 SP-Commits, eine Unterbrechung durch das Nutzungslimit von etwa 4 h ( `.git/logs/HEAD` 61→62) und QA auf Stufe C mit 18 Mutationsproben. Der PR-Lauf von T004 war wegen des Performance-Tests rot und musste geklärt werden ( `status.md:82–86` ).
2. **PO-Sitzung Block 1, 4,96 USD bei 23 Schritten:** T001 wurde auf Stufe C mit 33 Mutationen geprüft. Dazu kam die zusätzliche Härtungsaufgabe T003 in derselben Sitzung, insgesamt 3 SP/QA-Zyklen ( `lauf.jsonl` , Zeile 5).
3. **Change-Phase, 3,34 USD bei 23 Schritten:** 11 Doku-Commits mit zwei QA-Architektur-Reviews und Nacharbeit ( `.git/logs/HEAD` 40–50). Dazu kommen die Release-Schleifen mit 2 QA-Runden und 5 abgelehnten PowerShell-Aufrufen ( `lauf.jsonl` , Zeile 11).

## 4. Größte Kostentreiber

1. **Block 2 (Aufgaben T004 und T005), 5,82 USD:** T005 brauchte 8 Entwicklungs-Commits, es gab eine Unterbrechung durch das Nutzungslimit von etwa 4 Stunden und eine besonders strenge Prüfung (Stufe C) mit 18 Testproben. Der Lauf von T004 war wegen des Performance-Tests zunächst rot und musste geklärt werden ( `status.md:82–86` ).
2. **Block 1, 4,96 USD bei 23 Schritten:** T001 wurde auf Stufe C mit 33 Testproben geprüft. Dazu kam die zusätzliche Härtungsaufgabe T003 in derselben Sitzung, insgesamt 3 Zyklen aus Entwicklung und Prüfung ( `lauf.jsonl` , Zeile 5).
3. **Änderungsphase (Change), 3,34 USD bei 23 Schritten:** 11 Dokumentations-Commits mit zwei Architektur-Prüfungen und Nacharbeit ( `.git/logs/HEAD` 40–50). Dazu kommen die Release-Schleifen mit 2 Prüfrunden und 5 abgelehnten PowerShell-Aufrufen ( `lauf.jsonl` , Zeile 11).

## 5. Auffälligkeiten

- **Abgelehnte Berechtigungen:** 6, alle für Bash (1 in Block 1, 5 im Release wegen powershell.exe).
- **Limit:** Wartezeit von 240 Minuten durch das Nutzungslimit, vor allem in Block 2.
- **Abbruch:** keiner.
- **Unvorhergesehene Fragen:** 2; insgesamt 6 Rückfragen, davon 5 in der Planphase und 4 in der Änderungsphase laut Auditor-Zählung je Phase.
- **Regelverstöße:** R13 (T004 berührte zusätzlich `core/errors.py` und `core/domain.py` ) und R19 (die Prüfung auf Stufe B führte trotzdem die volle Testsuite aus).
- **Nicht prüfbar:** R18, weil es keinen eigenen roten Test-Commit gab.
- **Einschränkung des Auditors:** Der Start-Commit-Diff konnte nicht ausgeführt werden, weil Bash gesperrt war.
- **Manuelle Prüfung:** bestanden (17 Schritte, keine problematischen, geschätzt 8 Minuten für einen Menschen).

## 6. Manuelle Prüfung

Bestanden: ja · geschätzte Dauer für einen Menschen: 8 Minuten · Schritte: 17

Die Prüfung lief automatisch. Ein Mensch sollte die Verständlichkeit der Anleitung mit einer 10-Minuten-Stichprobe bestätigen.

## 7. Empfehlungen für die nächste Bibel-Version

1. **Bash-/PowerShell-Freigabe klären:** Die 6 abgelehnten Berechtigungen (5 davon im Release wegen powershell.exe) kosteten Schritte und behinderten sogar die Prüfung durch den Auditor. Die Vorlage sollte die benötigten Befehle vorab erlauben oder Alternativen nennen.
2. **Umfang pro Aufgabe schärfer begrenzen (R13):** Der T004-Diff berührte zusätzliche Dateien in `core/` . Der Brief sollte die erlaubten Dateien ausdrücklich nennen.
3. **Prüfstufe B klar eingrenzen (R19):** Die QA führte auf Stufe B die volle Suite inklusive Performance-Test aus ( `T006.md:91` ). Die Vorlage sollte festlegen, welche Tests auf welcher Stufe laufen.

4. **Stufe C gezielt einsetzen:** Block 1 und Block 2 waren die größten Kostentreiber (4,96 und 5,82 USD), mit 33 bzw. 18 Testproben auf Stufe C. Stufe C sollte nur für wirklich riskante Aufgaben gelten.
5. **Nachweis für Fehlerbehebungen festlegen (R18):** Bei den 2 echten Befunden (Doku und Testlücke) war die Regel nicht prüfbar. Die Bibel sollte sagen, wie bei Nicht-Codefehlern der Nachweis aussieht, und den Performance-Test vor dem ersten PR-Lauf prüfen lassen, weil T004 sonst rot wurde ( `status.md:82–86` ).