Prüfbericht Bibel 2.0

Automatischer Referenzlauf 42843123761 · Repository kassenbuch-2-0-42843123761 · 2026-11-10

Teilbericht: Der Lauf wurde abgebrochen (Kostenbremse: Projekt-Sitzungen über 20.0 USD).

1. Ergebnis

Der Lauf verbrauchte gegenüber der Vorversion Bibel 1.9 etwa 17,7 % mehr Tokens (25.945.593 statt 22.044.086) und etwa 12,8 % mehr Kosten (21,98 statt 19,49 USD). Er wurde von der Kostenbremse (Projekt-Sitzungen über 20,0 USD) abgebrochen: REL2 ist nicht übernommen, die Freigabe 3 für 2.0.0 steht aus. Die Regeltreue ist mit 22 von 25 Regeln gleich geblieben (R13 und R19 nicht erfüllt, R18 nicht prüfbar). Bei der Qualität sind alle 358 Tests und die CI grün, aber der Erstdurchlauf sank von 71 % auf 57 %, und es gab 5 echte Befunde statt 2.

2. Kennzahlen

Kennzahl	Bibel 1.9	Bibel 2.0
Datum	2026-11-10	2026-11-10
Claude-Code-Version	2.1.321 (Claude Code)	2.1.322 (Claude Code)
Tokens gesamt	22.044.086	25.945.593
Kostenschätzung (USD)	19,49	21,98
davon Koordinator	0,27	0,25
davon PO-Sitzungen (inkl. SP und QA)	19,21	21,73
Schritte	118	112
Aktive Laufzeit	79 Min.	91 Min.
Limit erreicht	ja, 240 Min. gewartet	ja, 210 Min. gewartet
Sitzungen	7	7
Aufgaben	7	7
Erstdurchlauf	71 %	57 %
QA-Runden	9	11
Echte Befunde	2	5
Rückfragen (davon unvorhergesehen)	6 (2)	5 (6)
Abgelehnte Berechtigungen	6	3
Regeltreue	22 / 25	22 / 25
Manuelle Prüfung (Minuten)	8	–

Kennzahl	Bibel 1.9	Bibel 2.0
Tests, CI grün	333, ja	358, ja
Bemerkung	Automatischer Lauf 42722790412	Abgebrochen: Kostenbremse: Projekt-Sitzungen über 20.0 USD

Hilfsaufrufe (Entscheider, manuelle Prüfung, Auditor, Bericht) zusätzlich: 1,21 USD, nicht in der Kostenschätzung enthalten.

3. Regeltreue und Auswertung

Kennzahl	Wert	Beleg
Sitzungen	7 (1 Koordinator, 6 PO)	lauf.jsonl, 7 verschiedene `session_id`
Schritte (num_turns)	112	Summe der Zeilen 1–14
Kosten (je Sitzung der letzte Wert)	ca. 21,98 USD	0,25 + 1,33 + 3,69 + 1,21 + 6,52 + 2,57 + 6,41
Aufgaben	7 (T001, T002, H001, REL, T003, T004, REL2)	docs/backlog.md
Erstdurchlauf	4 von 7 = 57 % (T002, H001, T003, T004)	docs/tasks/*.md, Abschnitt „Result“
QA-Runden	11 für Aufgaben (T001 3, REL 2, REL2 2, die übrigen je 1); dazu 1 QA-Prüfung der Änderung 1.1	docs/tasks/T001.md:72/110/147, REL.md:61/112, REL2.md:58/68
Echte Befunde	5 (T001: 2, REL: 2, REL2: 1); dazu 6 Befunde aus der Prüfung der Änderung 1.1	T001.md:75/116, REL.md:63, status.md:51
Abgelehnte Berechtigungen	3 (alle Bash mit Python-Heredoc)	lauf.jsonl Zeilen 3, 13, 14
Tests	358 (357 bestanden, 1 übersprungen)	status.md:44
CI	grün: Lauf 42893214103 (aeba598) ohne Fehler, Mutationstest eingeschlossen	status.md:11
Wartezeit durch Nutzungslimit	Lücke von etwa 3,8 Stunden zwischen den Aufrufen 8 und 9 (15:48 bis 19:35)	lauf.jsonl Zeilen 8–9
Offen am Ende	REL2 ist nicht in `main` übernommen, Freigabe 3 für 2.0.0 steht aus	status.md:3–4; `origin/main` = b943049

Regel	Ergebnis	Beleg
R1	erfüllt	Setup-Commit 9104b41 ändert nur CLAUDE.md, design.md und status.md (status-archive.md:443ff); settings.json: `"model"`, `autoMemoryEnabled:false`, Test-Hook. Den Diff selbst konnte ich nicht ansehen, weil kein Bash-Zugriff bestand.
R2	erfüllt	gate-plan.md:5 „Klasse S, eine gemeinsame Freigabe“; Architekturvorschlag ohne QA-Prüfung (status-archive.md:459)
R3	erfüllt	lauf.jsonl Zeile 2: „1. Widerspruch: Export gegen Nicht-Ziel N3“
R4	erfüllt	lauf.jsonl Zeile 3: Antwort nennt „Punkte 2 bis 5“, also 5 Rückfragen

Regel	Ergebnis	Beleg
R5	erfüllt	gate-plan.md:12–32 nennt Klasse, Bereitstellung, Prüfperson, „Personenbezogene Daten: nein“ und die Architektur in einfachen Worten
R6	erfüllt	architecture.md:66 „Gate-relevant decisions“, :272 „Removing a feature“
R7	erfüllt	Alle 7 Briefs haben in Zeile 2 eine QA-Stufe und einen Abschnitt „QA check criteria“
R8	erfüllt	backlog.md:12: letzte Zeile ist REL2
R9	erfüllt	Neue PO-Sitzung je Phase bzw. Block (Plan, Block 1 ×3, Change, Block 2); SP und QA laufen als Subagenten
R10	erfüllt	status.md hat 67 Zeilen; status-archive.md ist mit über 40 Übergaben gefüllt
R11	erfüllt	main-Reflog: Setup, Plan, T001/T002/H001 (Fast-Forward), CHANGE (REL steckt darin), T003, T004. Kein direkter Commit auf `main`.
R12	erfüllt	Schalter `export_csv` in config.toml (status-archive.md:257, :111)
R13	nicht erfüllt	Der Diff von T003 berührt zusätzlich core/config.py, `__init__.py`, ci.yml und .gitignore (status-archive.md:119–123)
R14	erfüllt	„Touches gate: yes“ mit QA-Prüfung der Änderung (status-archive.md:150–156); Entscheider antwortet „Freigeben“ (lauf.jsonl Zeile 12)
R15	erfüllt	Kern von T004 liegt in den Adaptern sqlite_store, takeover und entry_rows; dazu kleinere Änderungen in config, context, messages und service (status-archive.md:62–64)
R16	erfüllt	tests/core/test_config.py:43 `test_empty_env_var_is_error`; Sonden „directory as data file, missing folder“ (status-archive.md:207)
R17	erfüllt	tests/perf/test_list_perf.py: lokal 0,91 s, Grenze in der CI 3 s, Ziel 1 s (gate-plan.md:49)
R18	nicht prüfbar	Die Reihenfolge der Commits auf den Aufgaben-Branches war ohne `git log` nicht sichtbar. Der Fix für T001 meldet nur „failed before, passes now“ (status-archive.md:369).
R19	nicht erfüllt	Stufen A/B/C und mutmut als CI-Job sind vorhanden, nur eine Härtungsaufgabe (H001). Aber QA hat bei Stufe B die volle Suite laufen lassen (T002: „259 passed“, H001: „258 passed“, status-archive.md:241/209).
R20	erfüllt	ci.yml:5 `paths-ignore`; PLAN und CHANGE ohne CI-Lauf (status-archive.md:138, :423)
R21	erfüllt	Übergaben vermerken „checked once“ bzw. „not polled“; status.md:4 enthält eine „Waiting for“-Zeile
R22	erfüllt	Alle lokalen Branches zeigen auf denselben Commit wie `origin` (packed-refs, refs/heads = refs/remotes)
R23	erfüllt	manual-test.md: deutsch, Windows 11 und PowerShell, Schritte für Nicht-Entwickler. Die Prüfung durch den Entscheider steht nicht im Protokoll.
R24	erfüllt	Freigabe 1 (lauf.jsonl Zeile 4) und Freigabe 1b (Zeile 12) sind ausdrücklich erteilt. REL und REL2 sind ohne Freigabe 3 nicht übernommen.
R25	erfüllt	Actions per SHA eingebunden (ci.yml:17–18); requirements-dev.txt mit `==`; Negativtests vorhanden; Erlaubnisliste in gate-plan.md:37

- **Mutationstest mit mutmut in T001 und REL:** T001 brauchte 4 Zyklen aus SP und QA mit einer Eskalation an den Entscheider. Hinzu kamen 2 REL-Zyklen und jedes Mal ein Umweg

über die CI. Belege: status-archive.md:285–393 und :473–503, lauf.jsonl Zeile 5 (949 s, 3,69 USD).
- **Lange PO-Sitzungen mit mehreren Aufgaben und Subagenten:** Sitzung 1acb (T002, H001, REL) kostete 6,52 USD in 600 s. Sitzung 5687 (T003, T004, REL2) kostete 6,41 USD in 31 Schritten. Belege: lauf.jsonl Zeilen 9, 13, 14.
- **Doppelte Release-Vorbereitung und Nacharbeit an der Doku:** REL für 1.0.0 wurde komplett gemacht und dann durch REL2 ersetzt. Dazu kamen drei Commits nur für den Netzwerkpfad (6bd4f86, 40505ba, f376c99) und die Planung der Änderung mit 6 QA-Befunden für 2,57 USD. Belege: backlog.md:16–18, REL2-Reflog, lauf.jsonl Zeile 12.

4. Größte Kostentreiber

- **Mutationstest (mutmut) in T001 und REL:** T001 brauchte 4 Zyklen aus Umsetzung und Prüfung mit einer Eskalation an den Entscheider, REL weitere 2 Zyklen, jedes Mal mit Umweg über die CI. Beleg: status-archive.md:285–393 und :473–503; lauf.jsonl Zeile 5 (949 s, 3,69 USD).
- **Lange PO-Sitzungen mit mehreren Aufgaben:** Sitzung 1acb (T002, H001, REL) kostete 6,52 USD in 600 s, Sitzung 5687 (T003, T004, REL2) 6,41 USD in 31 Schritten. Beleg: lauf.jsonl Zeilen 9, 13, 14.
- **Doppelte Release-Vorbereitung und Nacharbeit an der Doku:** REL für 1.0.0 wurde komplett erstellt und dann durch REL2 ersetzt. Dazu kamen drei Commits nur für den Netzwerkpfad (6bd4f86, 40505ba, f376c99) und die Planung der Änderung mit 6 Befunden aus der QA-Prüfung für 2,57 USD. Beleg: backlog.md:16–18; lauf.jsonl Zeile 12.

5. Auffälligkeiten

- **Abbruch:** Kostenbremse bei über 20,0 USD für Projekt-Sitzungen. Die Gesamtkosten liegen bei 21,98 USD, zuzüglich 1,21 USD Hilfskosten.
- **Offen am Ende:** REL2 ist nicht in `main` übernommen, Freigabe 3 für 2.0.0 steht aus.
- **Nutzungslimit:** Wartezeit von 210 Minuten (Vorversion: 240 Minuten). Die Lücke liegt zwischen den Aufrufen 8 und 9 (15:48 bis 19:35).
- **Abgelehnte Berechtigungen:** 3, alle für Bash mit Python-Heredoc (lauf.jsonl Zeilen 3, 13, 14). Die Vorversion hatte 6.
- **Rückfragen:** 5, in den Kennzahlen sind 6 als unvorhergesehen geführt (Vorversion: 6, davon 2 unvorhergesehen). Die Zählweise sollte geprüft werden.
- **Änderungswunsch:** wurde gesendet. Die Prüfung der Änderung 1.1 ergab 6 Befunde.
- **Manuelle Prüfung:** nicht erfasst (Vorversion: 8 Minuten). Die Prüfung durch den Entscheider steht nicht im Protokoll.
- **Regeln:** R13 nicht erfüllt (T003 berührt zusätzlich core/config.py, `__init__.py`, ci.yml und .gitignore). R19 nicht erfüllt (QA ließ bei Stufe B die volle Suite laufen). R18 nicht prüfbar (Commit-Reihenfolge ohne `git log` nicht sichtbar).

6. Manuelle Prüfung

Nicht durchgeführt.

Die Prüfung lief automatisch. Ein Mensch sollte die Verständlichkeit der Anleitung mit einer 10-Minuten-Stichprobe bestätigen.

7. Empfehlungen für die nächste Bibel-Version

1. **Mutationstest in weniger Zyklen abschließen:** Mutmut-Vorgaben und Erwartungen schon im Aufgabenbrief festlegen, damit nicht mehrere Zyklen mit CI-Umweg nötig sind. Befund: T001 brauchte 4 Zyklen, REL 2 (3,69 USD in Sitzung 5).
2. **Release nur einmal vorbereiten:** REL erst starten, wenn Änderungswünsche und Freigaben geklärt sind. Befund: REL wurde durch REL2 ersetzt, dazu 3 Commits nur für den Netzwerkpfad.
3. **Sitzungen früher teilen oder Kostengrenze vorab prüfen:** Befund: Zwei Sitzungen kosteten je über 6 USD, der Lauf endete mit 21,98 USD an der Kostenbremse, bevor REL2 übernommen war.
4. **Regeln R13 und R19 schärfen:** Der Umfang einer Aufgabe soll vor der Übergabe gegen die genannten Dateien geprüft werden. QA soll bei Stufe B nur die gezielten Tests laufen lassen. Befund: R13 und R19 nicht erfüllt (T003; 259 bzw. 258 Tests in T002 und H001).
5. **Nachweisbarkeit verbessern:** Die Commit-Reihenfolge (rot vor grün) und die manuelle Prüfung sollen im Protokoll festgehalten werden. Das Berechtigungsmuster Bash mit Python-Heredoc soll vorab erlaubt oder vermieden werden. Befund: R18 nicht prüfbar, manuelle Prüfung null, 3 abgelehnte Berechtigungen.