Prüfbericht Bibel 2.1

Automatischer Referenzlauf 43054907244 · Repository kassenbuch-2-1-43054907244 · 2026-11-11

Teilbericht: Der Lauf wurde abgebrochen (PO Block 3: steckt fest, der Entscheider gab 3-mal dieselbe Antwort („Bitte prüf das selbst.“)).

1. Ergebnis

Dies ist der erste gültige Lauf, daher gibt es keinen Vergleich des Verbrauchs mit einer Vorversion (insgesamt 18,64 USD und 24.052.596 Tokens). Von 25 Regeln wurden 19 eingehalten, der Lauf brach aber in Block 3 ab, weil der Entscheider dreimal dieselbe Antwort gab; von 6 Aufgaben wurden die Freigabe-Aufgabe (REL) nicht begonnen und T004 und T005 nicht übernommen. Die Qualität ist gemischt: 60 % der Aufgaben bestanden im ersten Durchlauf, es gab einen echten Code-Fehler, die 303 Tests liefen laut Protokoll lokal grün, die automatische Prüfung (CI) war aber nicht grün.

2. Kennzahlen

Kennzahl	Vorversion	Bibel 2.1
Datum	–	2026-11-11
Claude-Code-Version	–	2.1.322 (Claude Code)
Tokens gesamt	–	24.052.596
Kostenschätzung (USD)	–	18,64
davon Koordinator	–	0,23
davon PO-Sitzungen (inkl. SP und QA)	–	18,41
Schritte	–	143
Aktive Laufzeit	–	73 Min.
Limit erreicht	–	ja, 210 Min. gewartet
Sitzungen	–	7
Aufgaben	–	6
Erstdurchlauf	–	60 %
QA-Runden	–	9
Echte Befunde	–	1
Rückfragen (davon unvorhergesehen)	–	23 (8)
Abgelehnte Berechtigungen	–	3

Kennzahl	Vorversion	Bibel 2.1
Regeltreue	–	19 / 25
Manuelle Prüfung (Minuten)	–	–
Tests, CI grün	–	303, nein
Bemerkung	–	Messaufbau M1 · Abgebrochen: PO Block 3: steckt fest, der Entscheider gab 3-mal dieselbe Antwort („Bitte prüf das selbst.“)

Hilfsaufrufe (Entscheider, manuelle Prüfung, Auditor, Bericht) zusätzlich: 1,3 USD, nicht in der Kostenschätzung enthalten.

3. Regeltreue und Auswertung

Kennzahlen (Teil 3 §7)

Kennzahl	Wert	Beleg
Sitzungen	7 (1 Koordinator, 6 PO)	`lauf.jsonl`: 7 verschiedene `session_id`
Schritte (`num_turns`)	139	Summe der Zeilen 1–25
Kosten (USD)	ca. 18,64 (Koordinator 0,23; Plan 1,32; Block 1 4,10; Block 2 2,87; Change 4,40; Block 3a 5,19; Block 3b 0,54)	Letzter `total_cost_usd` je Sitzung (der Wert steigt innerhalb einer Sitzung immer weiter)
Aktive Laufzeit	16:07–20:48 UTC; davon ca. 3,5 h ohne Aufruf zwischen Block 2 und Change	`zeit` in Zeile 1, 8 und 25
Aufgaben	6 (T001–T005, REL); REL nicht begonnen, T004 und T005 nicht gemergt	`docs/backlog.md` auf `main`, Branch `feature/T005-sqlite`
Erstdurchlauf	3 von 5 = 60 % (T001, T004, T005 PASS; T002 und T003 nicht)	`docs/tasks/T00x.md` „Result“, Commits 6e414c2, 081dfd7
QA-Runden	9 (7 für Aufgaben: T001 1, T002 2, T003 2, T004 1, T005 1; dazu 2 für das CHANGE-Review)	Commits 3fcb232, 6e414c2/8339eaa, 081dfd7/155d35f, 68dfba8, ec89d61, 538e91f/427e044
Echte Befunde	1 Code-Fehler (T003: `--Date` wird nicht mehr abgelehnt). Dazu ein Fehler im Brief von T002 und 7 Doku-Befunde im CHANGE-Review	081dfd7, 627214f, `status.md` Zeile 16
Abgelehnte Berechtigungen	3	`permission_denials` in Zeile 8, 12 und 21
Rückfragen Plan	5 (1 Widerspruch, 4 Lücken)	Zeile 2
Tests	303, laut Protokoll lokal grün (Stand T005-Branch)	Zeile 12

Kennzahl	Wert	Beleg
CI grün	nein: die Läufe 43096225532 und 43097322251 für T004 und T005 blieben „queued“	Zeile 19, Commit 28449d4

Regelprüfung R1–R25

Regel	Ergebnis	Beleg
R1	erfüllt	633842c ändert nur `CLAUDE.md`, `docs/design.md` und `docs/status.md`; `.claude/settings.json` setzt Modell, `autoMemoryEnabled:false` und Test-Hook
R2	erfüllt	`docs/tasks/ARCH.md:2` „class S: no QA review of the architecture“; eine Freigabe vor T001 (c318741)
R3	erfüllt	Zeile 2: „1. Widerspruch: Nicht-Ziel N3 und Funktion F02“ steht an erster Stelle
R4	erfüllt	Zeile 2: 1 Widerspruch und 4 Lücken = 5 Fragen
R5	nicht erfüllt	Zeile 4: Entscheider schickt zurück, weil Bereitstellung und Prüfperson fehlten
R6	erfüllt	`architecture.md:36` „Gate-relevant decisions“, `:274` „Removing a feature“
R7	erfüllt	Alle Briefs T001–T005 haben „QA level“ und „QA check criteria“ (der REL-Brief wurde nie geschrieben)
R8	erfüllt	`backlog.md:11` letzte Zeile ist `REL`
R9	erfüllt	Neue PO-Sitzung je Phase (6 Sitzungen); SP und QA liefen als Subagenten
R10	erfüllt	`status.md` hat 99 Zeilen; `status-archive.md` ist gefüllt (c394671)
R11	erfüllt	`main`: 511f432/633842c, dann je ein Squash-Commit mit ID (c318741 … b1e86a9)
R12	erfüllt	99b175c: Schalter `export_csv` in `config.toml`
R13	nicht erfüllt	Diff b1e86a9..d54bcdc ändert `src/core/errors.py` und `src/core/ports.py`, d. h. Teile von F02 lagen im Kern
R14	erfüllt	QA-Review CHANGE (538e91f, 427e044), erneute Freigabe 1 (0ed0b08, Zeile 11)
R15	erfüllt	d54bcdc..e9a6e98: der Code-Diff liegt überwiegend in `sqlite_store.py` und `legacy_json_migration.py` (kleinere Änderungen in core/config, ports, entries)
R16	nicht erfüllt	Auf `main` gibt es in `tests/core/test_config.py` keinen Test für einen ungültigen `KASSENBUCH_DATA`-Pfad; die Prüfung kam erst in T005, das nicht gemergt ist (Zeile 12)
R17	erfüllt	Perf-Test `tests/perf/test_list_perf.py`: 0,7 s gegen die CI-Grenze von 3,0 s, CI war grün bei T001 (Zeile 6)
R18	nicht erfüllt	7d200a7: Fix und Tests in einem Commit, ohne vorherigen roten Test
R19	erfüllt	Stufen A/B/C stehen in den Briefs; genau eine Härtungsaufgabe (T003)
R20	erfüllt	`ci.yml` hat `paths-ignore` für `docs/**` und `**/*.md`; Zeile 20: der Doku-Commit hat keinen Lauf ausgelöst
R21	nicht erfüllt	Zeilen 13–24: die CI wurde wiederholt abgefragt (z. B. Zeile 16: „Eben habe ich die CI noch einmal geprüft“)

Regel	Ergebnis	Beleg
R22	erfüllt	`git branch -a` : zu jedem lokalen Branch gibt es `origin/…`
R23	nicht erfüllt	`docs/manual-test.md` fehlt, weil REL nicht stattgefunden hat
R24	erfüllt	„Freigeben“ in Zeile 5 und 11; ohne grüne CI wurde nichts gemergt; Freigabe 3 wurde nicht erreicht
R25	erfüllt	Actions per SHA eingebunden (`ci.yml:24-25`); `requirements-dev.txt` mit `==` ; Erlaubnisliste in `settings.json` ; Negativtest `test_invalid_config_rejected`

Kostentreiber

- **Block 3, Sitzung 01cf5612 (5,19 USD):** Allein der erste Aufruf brauchte 14 Schritte und 7,27 Mio. Cache-Read-Tokens (Zeile 12). Danach kamen fünf weitere Aufrufe, in denen die CI wiederholt geprüft wurde (Zeilen 13–18). Die Folgesitzung 5d9d143d kostete für dasselbe Thema weitere 0,54 USD.
- **Change, Sitzung 5aba3b38 (4,40 USD):** 25 Schritte, ein QA-Review mit 7 Doku-Befunden, zwei Überarbeitungen der Architektur und eine Nachprüfung (Zeile 10, Commits 681512c–427e044).
- **Block 1, Sitzung fe0be079 (4,10 USD):** 203.164 Tokens 5-Minuten-Cache-Erstellung und 4,6 Mio. Cache-Read. Der T002-Durchgang lief zweimal durch QA, weil der Brief einen Fehler hatte (Zeile 6, 627214f).

4. Größte Kostentreiber

- **Block 3, Sitzung 01cf5612 (5,19 USD):** Schon der erste Aufruf brauchte 14 Schritte und 7,27 Mio. gelesene Cache-Tokens. Danach wurde die CI in fünf weiteren Aufrufen wiederholt abgefragt (Zeilen 13–18). Die Folgesitzung 5d9d143d kostete für dasselbe Thema weitere 0,54 USD.
- **Änderungswunsch (Change), Sitzung 5aba3b38 (4,40 USD):** 25 Schritte, ein Qualitätsreview mit 7 Doku-Befunden, zwei Überarbeitungen der Architektur und eine Nachprüfung (Zeile 10, Commits 681512c–427e044).
- **Block 1, Sitzung fe0be079 (4,10 USD):** 203.164 Tokens Cache-Erstellung und 4,6 Mio. gelesene Cache-Tokens. Aufgabe T002 musste zweimal durch die Qualitätsprüfung, weil der Auftrag (Brief) einen Fehler enthielt (Zeile 6, Commit 627214f).

5. Auffälligkeiten

- **Abgelehnte Berechtigungen:** 3 (Zeilen 8, 12 und 21).
- **Abbruch:** In Block 3 des PO blieb der Lauf stecken, weil der Entscheider dreimal „Bitte prüf das selbst.“ antwortete.
- **Limit:** ca. 210 Minuten Wartezeit; die Auswertung nennt ca. 3,5 h ohne Aufruf zwischen Block 2 und Änderungswunsch. Aktive Zeit: 73 Minuten.
- **Rückfragen:** 23 insgesamt, davon 5 im Plan (1 Widerspruch, 4 Lücken); 8 Fragen waren unvorhergesehen. Der Entscheider schickte die Planfragen einmal zurück, weil Bereitstellung und Prüfperson fehlten (R5).

- **CI:** Die Läufe 43096225532 und 43097322251 (T004, T005) blieben „queued“, die CI wurde dennoch wiederholt abgefragt (R21).
- **Abweichung bei den Schritten:** Die Kennzahlen nennen 143 Schritte, die Auswertung zählt 139 (Summe der Zeilen 1–25); der Unterschied ist ungeklärt.
- **Kosten:** Hilfskosten von 1,3 USD kommen zusätzlich vor; die Auswertung nennt für die Sitzungen ca. 18,64 USD insgesamt.

6. Manuelle Prüfung

Nicht durchgeführt.

Die Prüfung lief automatisch. Ein Mensch sollte die Verständlichkeit der Anleitung mit einer 10-Minuten-Stichprobe bestätigen.

7. Empfehlungen für die nächste Bibel-Version

1. **Entscheider-Antworten absichern:** Der Lauf brach ab, weil dreimal dieselbe Antwort kam („Bitte prüf das selbst.“). Die Bibel sollte festlegen, was der PO bei wiederholter Nicht-Antwort tut (z. B. begründet entscheiden und dokumentieren).
2. **CI-Abfragen begrenzen:** R21 nicht erfüllt; die CI wurde wiederholt abgefragt, das kostete in Block 3 5,19 USD plus 0,54 USD in der Folgesitzung. Vorgeben: höchstens eine Abfrage, dann Warten oder Abbruch mit Meldung.
3. **Planfragen vollständiger stellen:** R5 nicht erfüllt, weil Bereitstellung und Prüfperson fehlten. Diese Punkte als feste Pflichtfragen in den Plan aufnehmen.
4. **Briefs vor der Qualitätsprüfung prüfen und Kerngrenze klären:** Der Fehler im Brief von T002 verursachte eine zusätzliche QA-Runde (Commit 627214f); bei R13 lagen Teile von F02 im Kern (`errors.py`, `ports.py`). Briefs sollten Schichtzuordnung und Prüfkriterien ausdrücklich prüfen.
5. **Test-zuerst und Randfall-Tests erzwingen:** R18 (Fix und Tests in einem Commit, 7d200a7) und R16 (kein Test für ungültigen `KASSENBUCH_DATA`-Pfad auf `main`) nicht erfüllt; der echte Code-Fehler in T003 (`--Date` wird nicht mehr abgelehnt) passt dazu. Rote Tests vor dem Fix und Negativtests je Eingabe als Pflicht in die Briefs schreiben.